

# 一种随机可达的变异搜索机制

鲜 阳, 谭 飞, 李思宇

(四川轻化工大学自动化与信息工程学院, 四川 宜宾 644000)

**摘 要:** 一些经典随机优化算法如遗传算法、差分算法等变异机制存在不足, 导致算法全局搜索能力不高, 迭代次数、运行时间等指标数值较大。为此, 提出一种有效的变异设计机制, 即持续存在满足变异概率下子代个体在给定搜索空间内随机可达, 进而提高搜索能力和优化精度。通过对比实验得出, 该机制可有效提高算法的稳定性, 改善搜索能力, 同时增加找到最优解的机会, 即在后期种群趋同后仍具有跳出局部的能力。

**关键词:** 优化算法; 变异; 设计机制; 随机可达; 跳出局部

**中图分类号:** TP312    **文献标识码:** A    **文章编号:** 1009-2552(2022)06-0028-05

**DOI:** 10.13274/j.cnki.hdzj.2022.06.006

## A random reachable mutation search mechanism

XIAN Yang, TAN Fei, LI Si-yu

(School of Automation and Information, Sichuan University of Science & Engineering, Yibin 644000, Sichuan Province, China)

**Abstract:** The shortcomings of the mutation mechanism of some classic random optimization algorithms such as genetic algorithm and difference algorithm, the global search ability of the algorithm is not very high, and the number of iterations, running time and other indicators are relatively large. Therefore, an effective mutation design mechanism is proposed, in which the offspring individuals can be reached randomly in a given search space under the continuous existence of the mutation probability, thereby improving the search ability and optimization accuracy. Through comparative experiments show that this mechanism can effectively improve the stability of the algorithm, improve the search ability, and increase the chance of finding the optimal solution, which means the ability to jump out of the local area after the population converges in the later stage.

**Key words:** optimization algorithm; mutation; design mechanism; random reachability; out of the local

## 0 引 言

优化问题广泛存在于生产、生活等实际应用中, 即在有限的时间内找到满足特征和要求的较优解决方案。传统的最优化方法包括单纯形法、最速下降法、共轭梯度法等, 虽然这些方法可靠性强, 理论也比较成熟, 但通常要求待求解的问题有

精确的数学模型, 依赖于具体问题。进化算法是一种高效、并行、全局搜索的算法, 本身有着很好的兼容性, 已在多学科设计优化中得到广泛应用。自 20 世纪 60 年代以来, 迅速崛起并发展的智能优化算法, 如遗传算法、差分算法、蚁群算法、粒子群算法等以及算法间的结合使用对于求解各类优化问题的理论已经相对成熟<sup>[1]</sup>。

在发展过程中, 人们对其深入研究, 但更多的是对其实施步骤如选择、交叉方式和参数的研究<sup>[2-4]</sup>, 从整体上看, 这些环节占据了主要的地

**基金项目:** 国家自然科学基金(61902268); 四川省科技计划(2018JY0197, 19ZDZX0037, 2019YFSY0045, 2016-SZ0074)

**作者简介:** 鲜阳(1996-), 男, 硕士, 研究方向为智能控制。

位。变异(Mutations),易于理解且实现简单,在进化算法中被认为只是产生新个体的次要环节,因而重视程度远不及选择、交叉方式和参数的研究。文献[5-6]等提出的关于进化代数的自适应变异因子,作用于产生个体的主要步骤上,这种方法虽优于传统方法,但大都较复杂。部分学者也在变异上有着更深的研究,但大多数是通过各种不同的方法来实现变异,而没有从变异的本身考虑:变异应当以某一概率作用于种群中全部个体的所有部分,而不是仅仅局限于其实现方法。为此,本文提出了一种比较完备的变异机制,能使个体在给定搜索空间内随机可达,保持了种群的多样性,避免早熟,加快收敛速度,且不与实现变异的具体方法有关。

## 1 经典进化算法变异环节解析

变异作为一些进化算法中不可缺少的一部分,它是一个小概率发生的过程,可理解为是基因串上的某些位置发生突变从而形成新的遗传结构,此新个体一定程度上能为种群提供新的生存方向,也保证了种群内部的多样性。

### 1.1 遗传算法中的变异

遗传算法(Genetic Algorithms GA)是基于生物进化理论提出来的搜索最优解的仿生算法。从初始种群开始,对个体进行选择、交叉、变异操作,重复迭代直到取得最佳结果。在遗传算法中,是根据编码方式来确定变异方式,常用的是二进制编码和实数编码<sup>[7]</sup>。

二进制编码的变异过程中,在编码串上随机选一个位置将值求补,为翻转变异;选取两个位置交换对应的值,为交换变异;选取一小段打乱顺序排列,为倒换变异。即使让变异位数从一位增加到几位,对于多维问题可行性也依旧不高。

当采用实值编码进行变异时,一种是产生随机值来代替,另一种是生成一个原数值附近的数。理论上来说,遗传算法中的变异操作可以使算法避免早熟,但是为了保证算法的稳定性,变异概率通常取一个较小的数值。当出现早熟现象,传统的变异操作就需要迭代很多次,耗费更多计算时间才能变异出一个特殊的新个体。

### 1.2 差分算法中的变异

差分进化算法(Differential Evolution Algorithm DE)实现步骤与遗传算法类似。从种群里的多个点开始搜索,是一种并行式搜索,效率也比遗传算法高,因而能以较大概率找到整体最优解。在此算法中,变异操作可描述为:从种群中随机找出3个不同的个体 $x_{p1}, x_{p2}, x_{p3}$ 进行差异化组合。较经典的关系式为:

$$v_{ijg} = x_{p1j} + \lambda * (x_{p2j} - x_{p3j}) \quad (1)$$

其中, $v_{ij}$ 表示一个新个体; $x_{p1}, x_{p2}, x_{p3}$ 是个体在种群中的代号,它们随机且不同; $g$ 是代数; $\lambda$ 是缩放因子。

$\lambda$ 在算法中起着重要的作用,它控制种群多样性和收敛性,大小按需要设置。差向量的个数也可设计为两个,上式中仅有一个差向量。在实际MATLAB代码编写中, $\lambda$ 不一定采用某一固定值,可选择0到1之间的数去乘上一组与种群中个体同维度的随机数组,也可以将其设计成一个自适应参数。

差分进化算法中也有着其他的变异操作策略<sup>[8-10]</sup>,如式(2)-式(4):

$$v_{ijg} = x_{bestg} + \lambda * (x_{p2j} - x_{p3j}) \quad (2)$$

$$v_{ijg} = x_{p1j} + \lambda * (x_{p2j} - x_{p3j}) + \lambda * (x_{p4j} - x_{p5j}) \quad (3)$$

$$v_{ijg} = x_{bestj} + \lambda * (x_{p2j} - x_{p3j}) + \lambda * (x_{p4j} - x_{p5j}) \quad (4)$$

其中, $x_{bestg}$ 是 $g$ 代中最好的个体; $x_{p1}, \dots, x_{p5}$ 是五个不同的个体; $\lambda$ 是缩放因子。

在上式中,不同的策略对算法性能影响也会不同。比如式(1)中3个不同的个体使得种群多样性提高,式(2)中 $x_{bestg}$ 作为种群最优个体,有着指导作用。新个体 $v_{ij}$ 的产生是由其他个体进行向量组合而得到的,同遗传算法相比,可能算不上是真正意义上的变异。

## 2 新的变异机制

### 2.1 普通变异

变异操作,是对个体的某个或某段基因对应的值进行随机更改,从而得到新的个体。由于进化算法的随机性,当个体经过变异之后,所得到的新的那段基因,可能会与原种群中的某些个体所

对应的基因段相似甚至相同。这就意味着,这次变异是没有意义的变异,并没有产生特别的个体。到了程序运行的后面阶段,整个种群有可能陷入局部最优且每个个体趋同,这时候,就需要使变异的个体能够跃出那个局部最优的范围,而无效的变异,并不能达成目的。

## 2.2 新的设计机制描述

变异操作后的个体能够成为搜索空间里任意的一个点,是与众不同的,一定概率上能为种群提供新的生存搜索方向。换言之,要对种群中所有个体的每一维,按变异概率来决定是否变异,从而提高个体变异后的有效性,使其在搜索空间随机可达。

在变异的环节中,机制实现如下:

- ①遍历种群所有个体;
- ②对于多维个体,再遍历每个个体的位数;
- ③判断②中是否满足变异条件;
- ④进行变异操作及边界检查处理;
- ⑤种群刷新。

在算法中,无论采取何种手段来实现变异,都需保留这个机制,当种群陷入局部最优,算法停滞时,此机制产生的那些特别的个体能够避免这种情况发生,进一步得到最优解。

无需担心在程序里加入此机制会消耗更多的时间以及迭代次数,因为不满足的个体都将在下一步的选择操作中尽快的被过滤掉。选择的方法很多,常用的是择优法,即把进行变异前的种群复制一份,对副本操作,变异完成后,将副本个体值与原个体值进行比较,取其中适应值更好的一个作为新个体值。

## 3 验证与分析

为验证上述变异机制的可行性,选取以下几种函数进行分析<sup>[11]</sup>,这些函数对于传统的基于梯度的算法具有很强的欺骗性。

$$f(x) = 10d + \sum_{i=1}^d [x_i^2 - 10\cos(2\pi x_i)] \quad (5)$$

$$f(x) = \sum_{i=1}^{N/2} [100(x_{xi-1}^2 - x_{2i})^2 + (x_{2i-1} - 1)^2] \quad (6)$$

$$f(x) = \sum_{i=1}^d \frac{x_i^2}{4000} - \prod_{i=1}^d \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1 \quad (7)$$

$$f(x) = \sum_{i=1}^d x_i^2 \quad (8)$$

式(5)为 Rastrigin 函数,  $d$  表示维数,  $x = (x_1, x_2, \dots, x_d)$ , 最小值在  $x = (0, 0, \dots, 0)$  处取得, 即  $\min f(x) = 0$ 。

式(6)为 Rosenbrock 函数,  $N$  表示维数,  $x = (x_1, x_2, \dots, x_N)$ , 最小值在  $x = (1, 1, \dots, 1)$  处取得。

式(7)为 Griewank 函数, 其余同式(5)。

式(8)为 De Jong 函数, 其余同式(5)。

算法参数设置如下:种群数量为 100, 个体维度都为 10(取 10 个变量), 变异概率为 0.05, 最大迭代次数为 1000, 终止条件为精度小于  $10^{-5}$  或者达到迭代次数。

### 3.1 遗传算法求解

使用常规遗传算法搜索到多维函数的最优解显得比较困难, 表 1 为求解的结果(所有数据取 30 次运行结果的均值), 运行时间单位为秒。

表 1 遗传算法求解结果

所求函数	迭代次数	运行时间	最小值
Rastrigin	997.2667	0.224506	0.010726
Rosenbrock	1000	0.926938	0.7594514
Griewank	265	1.29587	0.08618605
De Jong	451	0.01600165	0.09474867

从表 1 中的数据可以看出, 求解结果的几项指标还不够好, 所迭代的次数也多, 最小值的精度还远远不够。

### 3.2 差分进化算法求解

一个多维度的点在使用梯度方法寻优的时候, 往往是有多个方向的, 在搜索中可能会增加随机性, 此时需要新的方法打破局面, 因而本文采取差分进化算法来研究<sup>[12]</sup>, DE 算法依赖梯度, 搜索非常快。

#### 3.2.1 常规变异方式

使用常规变异方式即随机选取个体以及位数来决定是否进行变异, 通过求解几种典型的优化测试函数, 得到的比较指标和最小值, 如表 2 所示。

表2 常规变异方式求解

所求函数	变异位数	迭代次数	运行时间	最小值
Rastrigin	1	774.4666667	0.477108333	4.01E-02
	3	417.8333333	0.413005667	1.02E-04
Rosenbrock	1	572.4666667	0.76245012	9.8809e-05
	3	498.8333333	0.65187337	9.3034e-05
Griewank	1	635.3	1.0569975	1.45E-02
	3	577	0.961496	1.79E-03
De Jong	1	55	0.067362	9.0778e-05
	3	48	0.041685	8.5165e-05

差分算法一定程度上优于遗传算法,表2中求得的数据已改善很多,迭代次数和运行时间都相应的减少,最小值的精确度更明显。

### 3.2.2 新的变异搜索机制

使用式(1)的变异方式,结合随机可达的变异机制,在满足变异概率的情况下( $\text{rand} < 0.05$ ),选取个体所有位随机的进行变异,结果如表3所示。

表3 新的变异搜索机制求解

所求函数	变异位数	迭代次数	运行时间	最小值
Rastrigin	随机位数	209.4666667	0.1202376	7.88E-05
Rosenbrock	随机位数	427.4666667	0.43832473	8.5764e-05
Griewank	随机位数	366.4	0.535499867	1.79E-03
De Jong	随机位数	44	0.028624	7.7627e-05

所求 Rosenbrock 函数的最优个体  $x$  为:

(0.99996, 0.99991, 0.99988, 0.99975, 0.99999, 0.99998, 1, 1, 1.0002, 1.0005)

所求 Rastrigin 函数的最优个体  $x$  为:

(-1.7638e-05, 8.3357e-06, -0.00017044, -0.00013513, 0.00022299, 0.00032815, -0.00031515, 0.0002771, -0.00033699, -2.6776e-05)

Griewank 函数和 De Jong 函数的最优个体与 Rosenbrock 函数的最优个体类似,因为都是在最小值在  $x = (0, 0, \dots, 0)$  处取得,就不予重复给出。

从表3中通过数据对比,在其他参数不变的情况下,与常规变异思想的求解结果相比较,迭代次数大量减少,运行所需时间也更低,进而迅速计

算出个体高达10维的解。从求解的个体可以看出精确度更高,已经非常逼近最优解。

### 3.2.3 种群重置

选取差分算法求解 Rastrigin 函数来着重突出此机制的随机可达性。在迭代搜索过程中,在迭代次数为100时,将种群所有个体随机的完全置于某个值和区域(这个随机的值或者区域有可能会接近于最优解或在其附近),来观测算法是否总能找到解,求解结果和最优解及迭代次数对应表4、图1-2所示。

表4 种群随机重置后求解结果

运行时间	迭代次数	重置后迭代次数	最小值
0.182916333	313.5333333	213.5333333	7.80E-05




图1 Rastrigin 函数取最优解时10个变量的值

表4以及图1图2中数据表明,直接将种群值赋在某位置,由于变异个体随机可达的机制在算法里,依旧能高效的找到解,其搜索能力、迭代次数、运行时间几乎不受太大的影响。总的迭代次数减去重置时的代数,剩余时间和代数与表3中的数据基本吻合。换言之,在后期种群趋同后,依旧有跳出局部的能力且基本不会出现达到迭代次数上限而终止的情况。

### 3.3 变异搜索图

下面给出仅在变异步骤中种群个体的分布,方便观测个体在给定空间里的搜索情况,如图3-5所示。






图2 收敛曲线




图5 迭代终止时的种群变异分布




图3 迭代初期种群变异个体分布




图4 迭代100次后种群变异分布

图3为迭代初期,种群中的个体都将试图找到使函数值变小的位置;图4为迭代中期,大部分个体已经收敛到最佳位置了;图5为迭代后期,此时已经达到算法设定的停止精度,但是由于此机制的存在,极少数个体仍然通过变异寻求其他可能存在的最优的位置,而未收敛的个体都将在下一步的选择操作中被过滤掉。但在算法里加入此变异机制后,能够使算法在运行时具有一定的稳定性,提高其效率。在解决上述问题时,当个体变异位数为1位和3位时,迭代次数偶尔会达到上限(1000次)而终止搜索,此时功耗增加、运行时间延长,得到的整体结果不理想。

#### 4 结束语

通过对进化算法变异环节的分析,从变异的本身来考虑,同时不局限于其实现方法的基础上,提出了一种新的变异设计机制,即持续存在满足变异概率下子代个体在给定搜索空间内随机可达,提高了算法搜索能力和优化精度,并在实验中通过取得的数据验证了其可行性,在进化算法中具有一定的理论意义,在实际问题的解决中提供了相应的思路。但本次研究也存在着一些尚待解决的问题:1. 未选取某些不典型的测试函数进行分析。2. 未在算法结合使用中探讨此机制的可行性。在今后的研究中会将此机制融合到进化算法并结合PID、神经网络等参数优化进行分析,并将其作为本文研究工作更进一步的研究方向。

(下转第38页)

## 参考文献:

- [1] 张广春. 茶文化环境下构建个性化高校学生心理健康教育机制平台[J]. 福建茶叶, 2017, 39(11): 189.
- [2] 陶信伟, 冯颖. 新媒体在特殊人群心理健康教育中的应用[J]. 中国健康教育, 2020, 36(2): 189-191.
- [3] 张志新, 张心祎, 骆玉峰, 等. 网络学习环境下中小学生学习心境状态测评研究[J]. 中国电化教育, 2019, 38(5): 27-33.
- [4] 宁淑娥, 魏刚, 付俊波, 等. 舰员战时应激心理能力测评系统预测性研究[J]. 解放军预防医学杂志, 2019, 37(12): 159-162.
- [5] 柳林, 刘引涛. 基于微信公众平台的高校学生心理健康管理系统设计[J]. 自动化技术与应用, 2020, 39(11): 166-168, 173.
- [6] 元礼娜. 社会主义核心价值观有机融入大学生核心素养体系研究[J]. 福建茶叶, 2019, 41(11): 158.
- [7] 李永慧. 大学生希望特质团体心理辅导干预效果评价[J]. 中国学校卫生, 2019, 40(1): 134-137.
- [8] 梁娟, 罗海据. 大数据挖掘方法在大学生心理预警系统中的应用[J]. 中国学校卫生, 2018, 39(12): 1821-1824, 1827.
- [9] 李科生, 念靖晴, 李琦, 等. “互联网+”心理平台: 大数据时代心理健康循证实践的新途径[J]. 中国临床心理学杂志, 2019, 27(1): 210-214, 205.
- [10] 李朝波. 探索在党校建立领导干部心理服务平台[J]. 中国党政干部论坛, 2019, 362(1): 36-39.
- [11] 刘德喜, 夏先益, 万常选, 等. 基于多特征融合的在线论坛用户心理健康自动评估[J]. 计算机学报, 2019, 42(7): 1553-1569.
- [12] 孟健男, 司维, 邵杰. 大学新生 SCL-90 心理测评研究——以某中医药大学药学院 2017 级新生为例[J]. 中国社会医学杂志, 2019, 36(4): 388-391.
- [13] 常斯维. 基于关联规则特征提取的心理大数据评估方法[J]. 周口师范学院学报, 2020, 37(2): 149-152.

(责任编辑: 杨静)

(上接第 32 页)

## 参考文献:

- [1] 沈小伟, 万桂所, 王一云. 现代智能优化算法研究综述[J]. 山西建筑, 2009, 35(35): 30-31.
- [2] 王春阳, 赵玉庆, 谢金兴, 等. 遗传算法变异算子的改进[J]. 山东农业大学学报: 自然科学版, 2019, 50(5): 898-901.
- [3] 杨从锐, 钱谦, 王锋, 等. 改进的自适应遗传算法在函数优化中的应用[J]. 计算机应用研究, 2018, 35(4): 1042-1045.
- [4] 曹道友, 程家兴. 基于改进的选择算子和交叉算子的遗传算法[J]. 计算机技术与发展, 2010, 20(2): 44-47, 51.
- [5] 刘勇, 于颖锐, 李满仓, 等. 基于自适应变异方法的差分进化算法[J]. 科技创新导报, 2019, 16(21): 136-138.
- [6] 王剑楠, 崔英花. 基于自适应变异算子的实数编码遗传算法[J]. 北京信息科技大学学报: 自然科学版, 2021, 36(2): 46-51.
- [7] 胡福年, 董倩男, 吕璐. 自适应二次变异的改进差分进化算法及其应用[J]. 计算机应用与软件, 2021, 38(7): 271-280.
- [8] 余兵. 差分进化算法及其应用[D]. 西安: 西安工程大学, 2007.
- [9] 沈鑫, 邹德旋, 张强. 采用双变异策略的自适应差分进化算法及应用[J]. 计算机工程与应用, 2020, 56(4): 146-157.
- [10] 周敏. 差分进化算法的改进及其应用研究[D]. 银川: 北方民族大学, 2021.
- [11] 石宏庆, 侯庆, 徐榛, 等. 优化算法测试函数综述及应用分析[J]. 计算机科学与应用, 2021, 11(11): 2633-2645.
- [12] 张楠楠. 差分进化算法的性能研究[D]. 兰州: 西北师范大学, 2019.

(责任编辑: 丁晓清)