



开放科学（资源服务）标识码（OSID）

基金项目:国家自然科学基金 National Natural Science Foundation of China (61902268); 四川省科技计划 Sichuan Provincial Science and Technology Program (2019YFSY0045); 省级大学生创新创业训练计划项目 Provincial College Students Innovation and Entrepreneurship Training Program (S202010622090,cx2021192)

## 基于改进逐行分类的车道线检测

鲜阳, 谭飞, 尹宋麟

(四川轻化工大学, 自动化与信息工程学院, 四川, 宜宾, 644005)

**摘要:**近年来车道线检测逐步向深度学习领域发展,然而基于分割的形状描述对车道线效率低下,同时像YOLO系列检测算法不适用于车道线这种细长、弯曲的物体。针对上述问题,文中提出一种基于改进逐行分类的车道线检测方法。选取ResNet作为主干网络,加入了特征金字塔模块(FPN)用于提取多尺度特征,并使用FTA(Feature Transfer Architecture)模块进行上下文信息的融合。其次,对于车道线实例区分,将实例检测应用于车道线,通过预测热图来检测车道线实例起始点,并回归相对应的一组卷积参数。然后,对于车道线形状预测,采用行分类方法并进行改进。使用逐行位置选择公式来确定车道线的点集,使用车道线在特征图上与真实位置的偏移量来细化每条车道线的形状,降低了FP值,实现了对车道线的预测。最后,在实验平台上使用Tusimple、CuLane两大基准数据集进行验证,取得了良好的指标与检测效果。

**关键词:** 车道线检测;逐行分类;FTA

中图分类号: TP391.41

文献标志码: A

### Lane line detection based on improved row by row classification

XIAN Yang, TAN Fei, YIN Songlin

(Sichuan University of Science & Engineering, School of Automation and Information Engineering, Yibin, Sichuan 644005, China)

**Abstract:** In recent years, lane line detection has gradually developed into the field of deep learning. However, shape description based on segmentation is inefficient for lane lines, and detection algorithms such as YOLO series are not suitable for such slender and curved objects as lane lines. To address the above issues, this paper proposes a lane line detection method based on improved row by row classification. ResNet was selected as the backbone network, and a Feature Pyramid Module (FPN) was added to extract multiscale features. The FTA (Feature Transfer Architecture) module was used to fuse context information. Secondly, for lane line instance discrimination, case detection is applied to lane lines, where the starting point of the lane line instance is detected by predicting a heat map, and a corresponding set of convolution parameters are regressed. Then, for lane line shape prediction, a row classification method is adopted and improved. The line-by-line position selection formula is used to determine the point set of the lane line, and the offset of the lane line from the actual position on the feature map is used to refine the shape of each lane line, reducing the FP value, and achieving prediction of the lane line. Finally, two benchmark datasets, Tusimple and CuLane, were used for validation on the experimental platform, and good indicators and detection results were achieved.

**Keywords:** Lane Line Detection; Line-by-Line Classification; FTA

## 0 引言

车道线检测一直是高级辅助驾驶系统(Advanced Driver Assistance Systems, ADAS)领域的一个热点, ADAS 通常会包含车道偏离预警、车道保持及转向灯变道等功能,而检测车道线的位置及属性信息是这些功能的关键环节<sup>[1]</sup>。在自动驾驶的新时期<sup>[2]</sup>,虽然感知系统会采用高精度地图、激光雷达等进一步补足和提升系统的能力,但是车道线检测在一些功能模块中依然发挥重要作用。无论是传统的 ADAS 领域,还是最新的自动驾驶系统,鲁棒、准确的车道线识别都是不可或缺的。由于车道线本身和各种环境因素,在真实场景中检测车道线具有挑战性,传统的检测方法已不能适应复杂多变的场景<sup>[3]</sup>。近年来,车道线检测逐步向深度学习领域发展<sup>[4]</sup>,基于深度学习的车道线检测主要分为以下三大类: 1.基于分割的方法,在这类方法中,车道线检测被建模为逐像素检测任务,并设计了各种增强模块。如 Pan 等人<sup>[5]</sup>提出了 SCNN,通过空间特征信息传递,解决了感受野小的问题; Hou 等人<sup>[6]</sup>提出了自注意力蒸馏模块 SAD(Self Attention Distillation)、使得网络能捕捉到丰富的上下文信息。2.基于检测方法,受目标检测的影响, E2E-LMD<sup>[7]</sup>、Lane-ATT<sup>[8]</sup>、UFSA<sup>[9]</sup>等将车道线图像分为一些 anchor 或 grid 进行检测,该类方法速度很快,但精度相对较低。3.基于点的方法,包括消失点<sup>[10]</sup>、关键点<sup>[11]</sup>引导等,这类方法考虑到了局部位置精度和全局形状信息,如文献[10]中提出一种自上而下的消失点引导锚方法,从而有效的捕获车道。

车道线的检测作为自动驾驶中的一项基本检测任务,由于所处环境的复杂性以及自身细、长且车道线数量可变,无论是传统的检测方法还是基于分割、锚点、行检测、参数预测等方法都有着各自的局限性。使用分割的方法对车道线检测效率较低且计算量复杂,而一般的检测方式不适用于车道线这种细长、弯曲的物体。基于此,本文提出一种基于改进逐行分类的车道线检测方法,处理了特征提取、实例检测、车道线解码中的问题,将车道线实例区分和行检测方法结

合起来,加以改进,取得了良好的检测效果,也保证了推理速度和精度。

## 1 车道线特征提取

特征提取一般作为图像处理的第一步,由于任务对象的大小、形状、位置各有其特点,对于某个特定任务,主干网络应适当调整,增添一些结构功能模块以应对具体目标的复杂性。对于车道线特征提取来说,车道在图像中占比少、不连续、遮挡破损严重,可以使用一种低层特征信息与高层特征信息融合的方法,尽可能的满足检测或者分割任务的需要;同时考虑到车道线具有细长的形状结构,特征分布不集中,实例点的预测是基于整条车道线的特征,需要用到上下文特征信息。本节对车道线特征提取进行探讨,针对多尺度特征与上下文信息的融合问题,使用了特征金字塔(FPN)以及提出FTA模块。

### 1.1 特征提取网络

本文在图 7 左边部分,使用 ResNet<sup>[12]</sup>作为主干网络,加入了 FPN<sup>[13]</sup>模块来合并不同尺度的特征,即 ResNet+FPN。我们应用网络实现对车道线特征的提取,图 1 为特征提取过程的一部分,输入图像为图 7 中的车道线图像原图,将其可视化利于理解车道线特征提取过程。




图 1 车道特征提取

Fig.1 Lane feature extraction

### 1.2 FTA模块

根据车道线在图像中分布由下而上、不连续、所占比例少等特点,在特征提取过程中,使用到图像的上下文信息具有一定的帮助。由于CNN本身的局限性,经过主干网络

所提取到的车道特征缺乏一定的信息，不利于后续工作中车道线的实例区分和解码。SCNN<sup>[5]</sup>网络采取的做法是先将特征图进行切片，然后再按照下、上、右、左的顺序进行卷积以获取各行列像素间的空间信息。但是在同一层相邻的片之间进行信息传递，这种顺序的信息传递方法使其计算花费较大，并且可能随着传播距离的延长，导致信息的丢失。

为解决特征信息传递问题，提出一种比SCNN模块效率更高的特征传递架(Feature Transfer Architecture, FTA)模块，添加了动态步长的概念。对于一个大小为  $C \times H \times W$

的特征图张量  $X$ ，首先在  $H$  维度（或者  $W$  维度）切片，得到  $H$  个（或  $W$  个）的特征向量，对于每个特征向量使用一个  $1 \times w$  的卷积核  $\bar{C}$  提取与其间隔  $s_k$  行的特征信息，

然后将卷积后的结果经过 *relu* 层，再与该特征向量进行叠加。这个过程表示为式(1)、

式(2)，其中， $\bar{C}$  是一个一维的卷积核组， $F$  是输入特征图， $i$  和  $j$  分别表示特征图的行

和列值， $T$  是信息传递的结果， $F_{c,i,j}^{k+1}$  表示经

过第  $k$  次  $F^k$  迭代更新后的结果。

$$T_{c,i,j}^k = \begin{cases} \sum_{m,n} \bar{C}_{m,c,n} \cdot F_{m,i+s_k,j+n-1}^k, & \text{horizontal} \\ \sum_{m,n} \bar{C}_{m,c,n} \cdot F_{m,i+n-1,j+s_k}^k, & \text{vertical} \end{cases} \quad 0 \leq i+s_k < H \quad (1)$$

$$F_{c,i,j}^{k+1} = F_{c,i,j}^k + \text{relu}(T_{c,i,j}^k) \quad (2)$$

与SCNN不同的是，我们FTA设计的步长  $s_k$  在每次迭代中是动态的，在特征传播中可以传到非相邻的节点。步长根据迭代次数呈2的指数递增，如式(3)、(4)所示，迭代总次数  $K$  由  $L$  决定， $L$  为特征进入FTA模块前下采样后的宽或者高。例如，288\*800的图像经过8倍下采样后，得出  $K$  等于4以及5（ $K$  值向下取整，且从0开始，长度减1），即在水平方向的切片  $H$  上迭代4次，竖直方向的切片上  $W$  迭代5次。

$$s_k = 2^k, \quad k = 0, 1, 2 \dots K-1 \quad (3)$$

$$K = \lfloor \log_2 L \rfloor \quad (4)$$

当特征图  $X$  在水平方向上分割成  $H$  个切片时，可以表示为：

$$\{X_0, X_1, X_2 \dots X_{H-2}, X_{H-1}\} \quad (5)$$

当第0次迭代时，步长  $s_k$  为1时， $X_0$  接

收来自  $X_1$  的信息；第1次迭代时，步长  $s_k$  为

2， $X_0$  接收来自  $X_1, X_2, X_3$  的信息；当第2次

迭代时，步长  $s_k$  为4， $X_0$  接收了来自  $X_1$  至

$X_7$  的信息，如图2所示。经过  $K$  次迭代之

后，每个位置都能够获得来自其他位置的信息，这对于细长的车道线特征是非常有用的。




图2 H维度从下到上传递

(Figure 2 Transfer of H dimension from bottom to top)

由于从左到右、从右到左、从上到下，从下到上迭代聚合特征信息差别不大且存在一定意义上的重复，因此设计的FTA模块采取了从下到上、从左到右两个方向。

## 2 实例区分

### 2.1 方法引入

车道检测的目的是要获取道路上每条车道线的走向和形状，还需要对每条车道线实例进行区分。为更好的解决车道实例区分问题，引入了文献[14]的思想，为每一个实

例生成对应的预测参数。首先找到实例对象然后回归一组核参，然后根据每个实例的核参预测车道线的形状，通过逐行方法自下而上的检测出车道线。以前方法的掩码头中的卷积核参数在训练后固定在所有的实例中，文献[14]的掩码头中的卷积核参数是动态生成的，是基于不同的实例。利用模块来检测生成实例，并为满足训练要求的实例生成对应的卷积参数，然后把实例中心位置的相关坐标特征串联到P3特征图上，最后使用控制器产生的卷积核去预测对应实例的mask。CondInst[14]网络框架如图3所示。

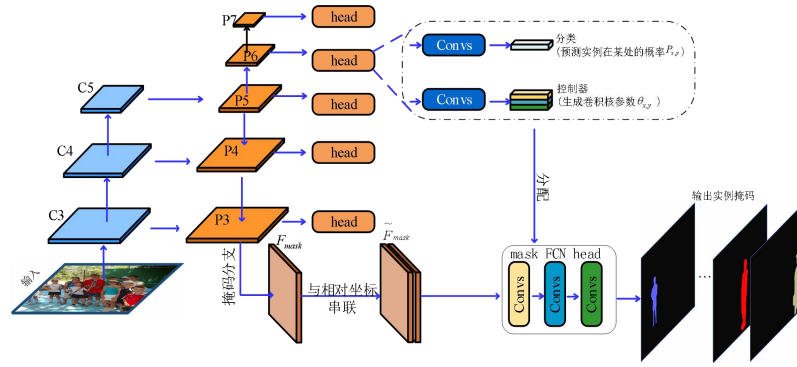


图 3 CondInst 网络框架

Figure 3 CondInst Network Framework

在下文通过预测热图(Heatmap)<sup>[15][16]</sup>来检测车道线实例，并对每个实例回归一组动态核参数，用于细化实例车道形状和位置，解决车道实例区分问题。

### 2.2 车道实例点

由于车道线呈现细长的形状且由近及远，通过检测车道线起点处的高响应点来检测车道实例，预测热图用于表示车道线的起点。如图7中的Instance detection head部分所示，输入图像在通过主干网络提取特征并聚合后，在高层次的特征图上检测车道实例，车道线检测实例过程可以描述为图4。




图 4 实例检测

Figure 4 instance detection

为指导分类的高响应区域落在车道线位置上，采用focal loss损失函数进行约束。

$$L_{point} = \frac{-1}{N_p} \sum_{xy} \begin{cases} (1 - \hat{P}_{xy})^\alpha \log(\hat{P}_{xy}) & P_{xy} = 1 \\ (1 - P_{xy})^\beta (\hat{P}_{xy})^\alpha \log(1 - \hat{P}_{xy}) & \text{otherwise} \end{cases} \quad (6)$$

其中， $P_{xy}$  是  $(x, y)$  处的标签， $\hat{P}_{xy}$  是

$(x, y)$  处的预测值， $N_p$  是输入图像中预定

义车道实例点的数量， $\alpha, \beta$  为 0 到 1 间的

超参数，热图包含的像素的标签为 1。此外，预测一个与热图相对应的参数图，形状大小为  $c \times h \times w$ ，包含了预测的动态卷积核参数对于起始点在某一个坐标点处的车道线实例。

## 3 行方向上车道线解码

### 3.1 行检测方法

在基于行分类车道线检测方法中，将车道线检测视为一个逐行分类问题。把车道线的图像区域划分为一个预定义的行锚框数，再将每个行锚框划分为一个预定义的网格单元数<sup>[9]</sup>。如图5所示，这样，车道线检测问题就变成在预定义的行锚框上选择特定的方格问题。



图5 车道表示

Fig.5 Lane representation

然而这种方法不够鲁棒，车道线建模约束单一，行与行之间缺乏连续性和一致性。比如像视野近处的车道线看上去比较宽，会占据多个网格，这会使得FP (False positive) 较高，即分类器预测结果是正样本，但其实是负样本。针对其存在的问题，使用逐行位置选择公式、车道线在特征图上的位置与真实位置的偏移量来描述每条车道线的形状。在逐行公式中，预测每行上的车道位置，然后根据线条形状的先验，按从下到上的顺序聚合位置以获得车道线。

### 3.2 逐行检测方法改进

#### 3.2.1 行上位置确定

将图像分为 $X \times Y$ 个网格，并预测相应的位置图，该位置图是图7中 Lane line prediction部分输出的特征图，每一行都有一个横坐标，表示了车道线的位置。为了获得行上有用的车道线位置，在每行中进行 $x$ 分类，即在每一行中选择响应最大的横坐标。然而遇到车道线占据多个网格的情况，这些网格都有着较高的响应。为了克服这个问题，对于每一行，预测车道线在网格中出现的概率，通过softmax输出最大值。

$$P_i = \text{softmax}(f_{loc}^i) \quad (7)$$

其中， $i$ 表示第 $i$ 行， $P_i$ 表示第 $i$ 行的概

率向量， $f_{loc}^i$ 表示位置图中第 $i$ 行的特征向量。为避免车道线像素点占据多个网格，使用横坐标的期望值来表示车道线像素点的位置：

$$E(\hat{x}_i) = \sum_j j \cdot p_{ij} \quad (8)$$

$E(\hat{x}_i)$ 为每行车道线的横坐标的期望值，

通过加权求和的方式计算得到， $p_{ij}$ 是每个坐标对应的概率值。在训练中应用L1损失函数回归车道线像素在网格的位置：

$$L_{row} = \frac{1}{N_v} \sum_{i \in V} |E(\hat{x}_i) - x_i| \quad (9)$$

$V$ 表示含有车道线的纵向范围，即Ground Truth对应包含的行数， $V$ 小于 $Y$ ，

$N_v$ 表示有效行数， $x_i$ 是实际位置。

#### 3.2.2 车道偏置信息

在实际中，因为网格的横坐标是在其左上角，描述不是特别准确，在每一行的水平方向上使用车道的偏置信息能更好的提高车道线位置的预测精度。在得到特征图维度的车道线定位之后，需要对车道线的具体位置进行确定，添加偏移图来预测每一行在水平方向上靠近行位置的偏移量，在车道线附近定义一个小范围区域，用 $\nabla$ 表示，使用损失函数来约束：

$$L_{bias} = \frac{1}{N_{\nabla}} \sum_{(j,i) \in \nabla} |\hat{\beta}_{i,j} - \beta_{i,j}| \quad (10)$$

其中 $\hat{\beta}_{i,j}$ 表示预测的偏移量， $\beta_{i,j}$ 表示

真实偏移量， $N_{\nabla}$ 表示 $\nabla$ 中像素个数。

#### 3.2.3 车道表示

为了方便拟合和绘制车道线，将检测到的车道线使用点集来表示，对于第 $k$ 条车道线，第 $i$ 行的位置坐标 $(x_k^i, y_k^i)$ 描述如下：



$$\begin{cases} y_k^i = H / Y \cdot i \\ x_k^i = W / X \cdot (loc_k^i + \beta(loc_k^i, i)) \end{cases} \quad (11)$$

其中  $i \in [v_{\min}^k, v_{\max}^k]$ ,  $[v_{\min}^k, v_{\max}^k]$  为车道

有效行的一个范围,  $loc_i^k$  表示  $E(\hat{x}_i)$  取整结

果,  $\beta(\cdot)$  表示预测的偏移量,  $W, H$  是图像

的高和宽,  $X, Y$  是图像网格化的一个范围。

在图7右侧车道线解码部分, 在主干输出的特征图上, 利用Instance detection head部分得到的实例信息和卷积参数, 计算每行上大致的位置图和偏移图。位置图为单通道的特征图, 对于每行的特征数据, 先做Softmax, 再根据Softmax的输出与列坐标加权求和, 得到该行的车道线位置。位置计算一般具有偏差, 通过网络预测一个偏置信息用于提高车道线位置的预测精度。在训练阶段, 总的损失函数表示为:

$$L_{total} = L_{point} + L_{row} + L_{bias} \quad (12)$$

## 4 算法流程

对算法流程简要总结如下:

- 1.输入图像;
- 2.主干网络提取特征,加入FTA模块传递上下文空间信息;
- 3.预测热图找出车道线大致的实例起始点并返回卷积核参数, 用于步骤4中;
- 4.行检测方法改进(位置选择、偏移量);
- 5.在原图上绘制车道线, 进行输出。




图 6 算法步骤

Fig.6 Algorithm step

网络结构图如图7所示, 主干采用ResNet50+FPN结构, 进行多尺度特征提取, 添加了FTA模块以实现更有效的上下文特征提取。Instance detection head部分输出两个特征图, 热图heatmap预测车道线起点处的高响应点来检测车道实例, 参数图与热图一一对应, 输出网格中车道线实例对应的卷积参数, 用于在Lane line prediction中计算该网格对应的车道线信息。车道线预测中采用逐行检测方法, 预测车道线逐行位置和偏移量, 最后在图上进行车道线的可视化输出。

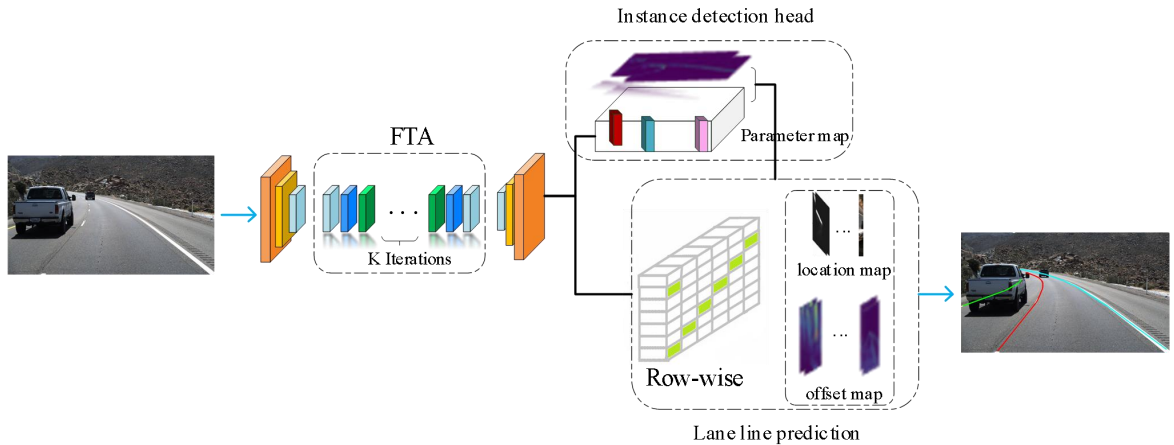


图 7 车道线检测网络

Fig.7 Lane Line Detection Network

## 5 实验分析

### 5.1 数据集和实验配置

Tusimple数据集是一个专门针对真实高速公路场景的自动驾驶数据集, 约20G左右, 其中3626张图像用于训练, 2782用于测试。对于这个数据集, 评价指标有FP、FN和准

确率，准确率计算见式(13):

$$accuracy = \frac{\sum_{clip} C_{clip}}{\sum_{clip} S_{clip}} \quad (13)$$

其中， $C_{clip}$  表示每个clip中正确预测的车道线点数， $S_{clip}$  表示每个clip中的地面真相总值。

CULane数据集是一个有着9种不同场景的大型车道线检测数据集，数据集分为88880个训练集，9675个验证集和34680个测试集，每张图像大小为1640\*590。这个数据集采用F1来度量，利用预测车道线与地面真相标签之间的IoU来判断样本是真正例 (TP)、假正例 (FP) 还是假负例 (FN)，F1指标的计算如下式：

$$precision = \frac{TP}{TP + FP} \quad (14)$$

$$recall = \frac{TP}{TP + FN} \quad (15)$$

$$F1 = \frac{2 \times precision \times recall}{precision + recall} \quad (16)$$

目前的大多数方法在 Tusimple 和 CULane数据集上正确率都达到了饱和，于是采用F1得分来突出自己的方法性能，文中也主要采取F1分数来对比。本文实验使用的显卡为NVIDIA Geforce1080Ti，显存大小11GB；操作系统为Ubuntu20.04；软件配置为Pycharm；编程语言为Python；深度学习框架为Pytorch。

## 5.2 检测结果

在 Tusimple 数据集上的检测结果如图8所示，上方为输入原始图像，中间为地面真相，下方为对应的车道线检测结果。在弯道、阴影及遮挡情况下，均取得了较好的检测效果，线颜色的不同表示检测到的不同的车道线实例。

此外，选取了文献[17]和UFSA<sup>[9]</sup>与文中方法在原图上进行比对，如图9所示，文中方法结果见分图（d）。

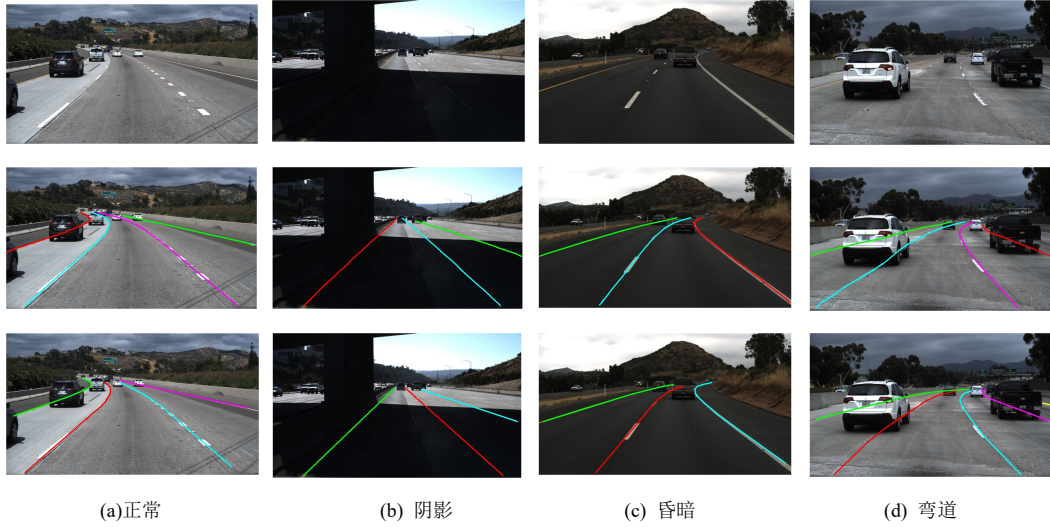


图8 Tusimple 数据集上的检测结果

Fig.8 Detection results on the Tusimple dataset




图 9 检测结果对比示例

(Figure 9 Comparison examples of test results)

本文方法采取了 ResNet+FPN 特征提取网络结构以及 FTA 模块，捕获到了车道线精细的特征，也对所检测到的车道线进行了区分，从结果上来看略优于其他方法，通过线条精细化的绘制而不是点，在视觉上更符合车道线的检测结果。通过特征提取以及 FTA 模块的高效信息传递，对于较远处的车

道线也能更好的识别；通过逐行检测方法的改进处理，检测到的车道线位置更精确，不会有太大的位置偏离，尤其是近处的车道线。

在 CULane 数据集上的检测结果如图 10 所示，第一行为原始图像，中间行为地面真值，最后一行为检测结果图。




图 10 CULane 数据集上的检测结果

Fig.10 Detection results on the CULane dataset

### 5.3 对比实验

本节中分别与其他几种车道线检测算法（基于分割、基于行检测、基于点的方法）

在同一数据集上进行比较，如表1所示。表中UFSA速度很快(300+FPS)，但图像网格上车道线的位置分布未得到很好的处理，车道



线的形状描述不强,使得FP较高,F1得分略低。文中方法从逐行位置选择公式上和车道线偏移量上来进行改善,通过逐行位置确定的改进,降低了FP值,取得了F1为96.29%的成绩,同时也能满足实时性。同时在准确度方面达到了96.21%,高于UFSA0.39%,总体上和基于分割的方法相差不大乃至有一定的提升空间。

表 1 Tusimple 数据集上不同方法比较

Table 1 Comparison of different methods on Tusimple dataset

方法	测试指标				
	F1	Acc	FP	FN	FPS
PolyLaneNet <sup>[18]</sup>	90.62	93.36	9.42	9.33	115.0
EL-GAN <sup>[19]</sup>	96.26	94.90	4.12	3.36	10.0
SCNN <sup>[5]</sup>	95.97	96.53	6.17	<b>1.80</b>	7.5

表 2 CULane 数据集上不同方法比较

Table 2 Comparison of different methods on the CULane dataset

方法	F1、测试场景、FPS										
	Total	Normal	Crowded	Dazzle	Shadow	No line	Arrow	Curve	Cross	Night	FPS
SCNN <sup>[5]</sup>	71.60	90.60	69.70	58.50	66.90	43.40	84.10	64.40	1990	66.10	7.5
SAD <sup>[6]</sup>	70.80	90.10	68.80	60.20	65.90	41.60	84.00	65.70	1998	66.00	75
CurveLane <sup>[20]</sup>	71.4	88.3	68.6	63.2	68.0	47.9	82.5	66.0	2817	66.2	-
PINet <sup>[11]</sup>	74.40	90.30	72.30	66.30	68.40	49.8	83.70	65.60	1427	66.70	-
文献 <sup>[10]</sup>	76.12	91.42	<b>74.05</b>	66.89	72.17	<b>50.16</b>	87.13	67.02	<b>1164</b>	<b>70.67</b>	117
E2E-LMD <sup>[7]</sup>	74.00	91.00	73.10	64.50	74.10	46.60	85.80	71.90	2022	67.90	-
LaneATT <sup>[8]</sup>	75.09	91.14	72.96	65.72	68.03	48.35	85.49	63.37	1170	68.95	250
ENet <sup>[21]</sup>	68.8	88.4	67.0	57.4	63.4	42.9	81.9	62.6	2768	61.4	-
UFSA <sup>[9]</sup>	68.40	87.70	66.00	58.40	62.80	40.20	81.00	57.90	1743	62.10	<b>322.5</b>
Ours	<b>76.14</b>	<b>91.87</b>	71.79	<b>70.72</b>	<b>74.3</b>	45.34	<b>89.37</b>	<b>72.40</b>	1364	67.4	217

从本文与其他效果实验对比可知,所提方法一定程度上优于其他方法,避免了基于分割方法中繁琐的后处理和计算消耗,也免去了基于点方法中anchor的设置;通过预测

## 6 结语

提出了一种改进逐行分类的车道线检测方法:首先,对于特征提取部分,针对车道线这种细长型的物体检测,使用ResNet+FPN的网络结构作为车道线特征提取主干,用于捕获车道线精细的特征,同时使用了FTA模块进行上下文信息的融合;然后,在车道线的实例检测中,引入了动态卷积的方法,通过预测热图来检测车道实例起始点,为每一个车道实例生成对应的预测

SAD <sup>[6]</sup>	95.92	<b>96.64</b>	6.02	2.05	75.0
PINet <sup>[11]</sup>	-	95.81	5.85	3.36	40
文献 <sup>[10]</sup>	-	95.87	-	-	92
UFSA <sup>[9]</sup>	87.87	95.82	19.05	3.92	<b>312.5</b>
Ours	<b>96.29</b>	96.21	<b>2.18</b>	3.80	220

表 2 为本文方法在 CULane 数据集上和其他方法的结果统计,在 9 大场景中,由于夜间和没有车道线的场景难度较大,均不易检测。IoU 阈值设置为 0.5,对于 Cross 场景,用 FP 表示。文中方法在其中多个场景中取得了优于其他方法的成绩,FPS 达到了 217,F1-measure 为 76.14%,速度和精度上达到了相对平衡。由于严重遮挡和无视觉线索的存在,在 No line、Night 等场景中出现表现不佳的情况。

热图检测车道实例,较好的解决了车道线的实例级区分问题,同时采用快速高效的行分类思想对车道线解码,从而提升了检测速度。

参数,解决了车道实例级判别的问题;其次,车道线解码中,叙述了逐行方法的思路及缺陷,从逐行位置选择上和车道位置偏移量上进行改进;最后,在两个大型车道线检测数据集上进行算法验证,并与之前的工作进行可视化对比和指标对比,所提出的方法在Tusimple上F1值为96.29%,正确率为96.21%,同时降低了FP值;在CULane数据集上的多个场景中取得了优于其他方法

的成绩, FPS 达到了 217, F1-measure 为 76.14%, 速度和精度上达到了相对平衡。本章所提出的方法解决了相应的问题, 在一定程度上略优于其他方法。

#### 参考文献:

- [1] Yurtsever E, Lambert J, Carballo A, et al. A survey of autonomous driving: Common practices and emerging technologies. *IEEE Access*, 2020(8): 58443-58469.
- [2] 王金强,黄航,鄧朋,申泽邦,周庆国.自动驾驶发展与关键技术综述[J].电子技术应用,2019,45(06):28-36.DOI:10.16157/j.issn.0258-7998.199062.
- [3] 刘宇,韩磊,王程庆,孙扬.基于视觉的车道线检测算法研究综述[J].汽车实用技术,2021,46(22):24-27.DOI:10.16638/j.cnki.1671-7988.2021.022.006.
- [4] 杨荣锦,张秀峰,龚莉娜,牛选兵,王伟,马天翼.基于深度学习的车道线检测方法综述[J].大连民族大学学报,2021,23(01):40-44.
- [5] Pan X, Shi J, Luo P, et al. Spatial as deep: Spatial cnn for traffic scene understanding[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).
- [6] Hou Y, Ma Z, Liu C, et al. Learning light weight lane detection cnns by self attention distillation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1013-1021.
- [7] Yoo S, Lee H S, Myeong H, et al. End-to-end lane marker detection via row-wise classification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020: 1006-1007.
- [8] Tabelini L, Berriel R, Paixao T M, et al. Keep your eyes on the lane: Real-time attention-guided lane detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 294-302.
- [9] Qin Z, Wang H, Li X. Ultra fast structure-aware deep lane detection[C]//European Conference on Computer Vision. Springer, Cham, 2020: 276-291.
- [10] Su J, Chen C, Zhang K, et al. Structure Guided Lane Detection[J]. arXiv preprint arXiv:2105.05403, 2021.
- [11] Ko Y, Lee Y, Azam S, et al. Key points estimation and point instance segmentation approach for lane detection[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- [12] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [13] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [14] Tian Z, Shen C, Chen H. Conditional convolutions for instance segmentation[C]//European conference on computer vision. Springer, Cham, 2020: 282-298.
- [15] Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 6569-6578.
- [16] Law H, Deng J. Cornernet: Detecting objects as paired keypoints[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 734-750.
- [17] Pizzati F, Allodi M, Barrera A, et al. Lane detection and classification using cascaded CNNs[C]//Computer Aided Systems Theory - EUROCAST 2019: 17th International Conference, Las Palmas de Gran Canaria, Spain, February 17 - 22, 2019, Revised Selected Papers, Part II 17. Springer International Publishing, 2020: 95-103.
- [18] Tabelini L, Berriel R, Paixao T M, et al. PolyLaneNet: Lane estimation via deep polynomial regression[C]//2020 25th International Conference on Pattern Recognition (ICPR). IEEE,

然而当前诸多车道线检测算法未工程实践化, 实际应用效果与测试的结果会存在一个难以控制的差异, 在更进一步的研究中拟将车道线检测模型部署在 ROS 环境中。

2021: 6150-6156.

- [19] Ghafoorian M, Nugteren C, Baka N, et al. El-gan: Embedding loss driven generative adversarial networks for lane detection[C]//proceedings of the european conference on computer vision (ECCV) Workshops. 2018: 0-0.
- [20] Xu H, Wang S, Cai X, et al. Curvelane-nas: Unifying lane-sensitive architecture search and adaptive point blending[C]//European Conference on Computer Vision. Springer, Cham, 2020: 689-704.
- [21] Hou Y. Agnostic lane detection[J]. arXiv preprint arXiv:1905.03704, 2019.

作者简介:



鲜阳，男，（1996—），四川轻化工大学电子信息专业，在读硕士研究生。主要研究方向：图像处理、车道线检测。



谭飞，男，（1972—），电子科技大学信号与信息处理硕士，副教授。主要研究方向：智能控制和计算机应用研究。



尹宋麟，男，（1997—），四川轻化工大学电子信息专业，在读硕士研

究生。主要研究方向：图像处理和智能算法。

通信地址：四川省宜宾市翠屏区四川轻化工大学宜宾校区。

邮编：644000

鲜阳，联系方式（手机，email）：19162798047，xy\_mts@163.com